Projet SMA : le guide

Températures extrêmes à Brest – le projet et la compétition du groupe

L'essentiel

- **Le projet du prof :** un notebook par groupe, à déposer sur Moodle avant le **vendredi 30 octobre**. Deux parties : des statistiques sur le passé, et une prédiction des températures jusqu'en 2100.
- **Notre compétition :** pour la prédiction, chacun cherche son modèle. Le meilleur devient le modèle du notebook.
- **L'objectif :** prédire les températures de 2001 à 2025 en n'ayant appris que sur 1940–2000.
- **Le score final :** un seul nombre, le **CRPS du maximum annuel sur 2001–2025**, en °C. Le plus bas gagne. Chacun lance le benchmark lui-même, autant de fois qu'il veut.

1. Le principe

Chaque année a une température **maximale** et une température **minimale** (la plus haute et la plus basse de l'année, en °C). On veut les prédire à partir du **CO2** mondial de l'année (en ppm).

Pour savoir quel modèle prédit le mieux, on fait comme si on était en 2000 : le modèle apprend sur 1940–2000, prédit 2001–2025, et le benchmark compare aux vraies valeurs.

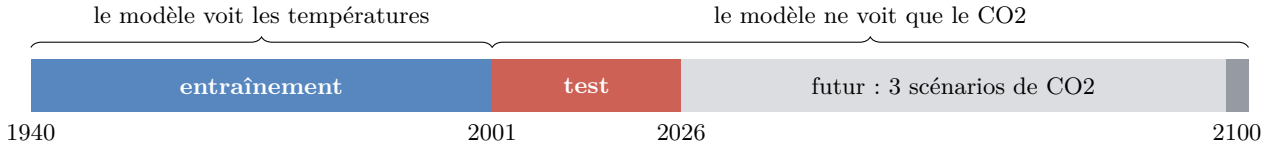

- **Entraînement (1940–2000)** : les seules températures que le modèle a le droit d'utiliser.
- **Test (2001–2025)** : c'est là-dessus qu'on est noté.
- **2100** : pas de vraie valeur, donc pas de note. On vérifie seulement que les prédictions ne sont pas absurdes.

Les trois scénarios de CO2 sont ceux du GIEC, appelés SSP. En 2100, le CO2 vaut 400 ppm dans SSP1-2.6 (monde sobre), 527 ppm dans SSP2-4.5 (intermédiaire) et 946 ppm dans SSP5-8.5 (monde très fossile). Aujourd'hui il vaut environ 430 ppm.

2. Ce que ton modèle doit produire

On ne prédit pas une valeur mais 10 000. Le prof demande une prédiction probabiliste : pour chaque année, le modèle donne **10 000 tirages**, c'est-à-dire 10 000 valeurs plausibles de la température. S'ils sont resserrés, le modèle est sûr de lui ; s'ils sont étalés, il hésite.

Pour lancer le benchmark, il faut exactement ceci :

Pour le test	pour chaque année de 2001 à 2025 : 10 000 tirages du maximum et 10 000 tirages du minimum
Pour 2100	pour chacun des 3 scénarios : 10 000 tirages du maximum et 10 000 tirages du minimum

La méthode est libre. C'est là qu'il faut réfléchir : quelle relation entre le CO2 et la température, et comment représenter l'incertitude.

Le modèle de référence. Le kit contient un modèle simple, **fait par nous** (pas par le prof ni par l'école), qui sert de point de départ et de score à battre. Il suppose que la température suit une droite en fonction du logarithme du CO2, plus un aléa de loi normale. Son score final est de **1,70 °C**.

3. Comment on est classé

Le benchmark est dans le kit. Chacun le lance sur son modèle quand il veut : il affiche le résultat des tests de cohérence et le score. Le classement se fait en trois étapes.

Étape 1 : les 3 tests de cohérence (éliminatoires)

Ils portent sur les prédictions pour 2100, que personne ne peut vérifier. Ils écartent les modèles bons sur 2001–2025 mais absurdes à long terme. Rater un seul test, pour le maximum ou pour le minimum, élimine.

1. **Plus de CO2 ne refroidit pas.** En 2100, la médiane des tirages doit augmenter d'un scénario au suivant : SSP1-2.6 $\leq$ SSP2-4.5 $\leq$ SSP5-8.5, à 0,1 °C près.
2. **L'incertitude ne rétrécit pas.** En 2100 sous SSP5-8.5, les tirages doivent être au moins aussi étalés que sur 2001–2025. On compare la largeur de l'intervalle qui contient 80 % des tirages.
3. **Pas de valeur absurde.** Tous les tirages restent entre 0 et 50 °C pour le maximum, entre −30 et 20 °C pour le minimum.

Étape 2 : le score final

Le score final

Le **CRPS du maximum annuel, moyenné sur les 25 années 2001–2025**. Il est en °C. **Le plus bas gagne.** À battre : 1,70 °C.

Le CRPS compare les 10 000 tirages $x_1, \ldots, x_N$ d'une année à la vraie valeur y de cette année :

$$\text{CRPS} = \underbrace{\text{moyenne des } |x_i - y|}_{\text{distance des tirages à la vérité}} - \tfrac{1}{2} \underbrace{\text{moyenne des } |x_i - x_j|}_{\text{étalement des tirages}}.$$

— Si les tirages sont loin de la vraie valeur, le score monte.
— Si on étale les tirages pour se couvrir, ils s'éloignent aussi de la vraie valeur, et le score monte.
— Le meilleur score s'obtient avec des tirages **bien centrés et ni trop larges ni trop étroits**.
— Si les 10 000 tirages sont tous égaux, le CRPS est simplement l'erreur en °C.

Étape 3 : en cas d'égalité

Avec seulement 25 années, deux modèles proches peuvent être départagés par la chance. Si deux scores finaux sont à moins de **0,05 °C** l'un de l'autre, c'est une égalité : le gagnant est celui qui a le meilleur **CRPS du minimum annuel**, que le benchmark affiche aussi.

4. Les règles

1. **Le modèle n'apprend que sur 1940–2000.** Pour 2001–2025 et pour 2100, il n'utilise que le CO2.
2. **Aucune donnée ni connaissance extérieure** : pas d'autre station, pas de « je sais que 2022 a été caniculaire ».
3. Le score annoncé doit pouvoir être reproduit par les autres en relançant le modèle.

5. Le notebook à rendre au prof

Le sujet est de Pierre Tandeo. On complète le notebook qu'il fournit. Les deux parties sont obligatoires.

Partie 1 : statistiques sur le passé (température de chaque jour, 1940–2025)

1. **Le cycle saisonnier.** Pour chaque jour de l'année (1 à 365), calculer les quantiles à 10 %, 50 % et 90 % des températures de ce jour sur toutes les années, puis les lisser par une moyenne glissante d'un mois. Tracer les trois courbes et commenter.
2. **Les vagues de chaleur.** Un jour est chaud s'il dépasse le quantile à 90 % de son jour de l'année. Une vague de chaleur est une suite de jours chauds consécutifs. Calculer pour chacune sa durée (en jours) et son intensité (écart moyen à la normale, en °C).
3. **Le diagramme intensité–durée.** Un point par vague, coloré par année. Commenter.

Le sujet laisse des choix ouverts, à trancher et à écrire dans le notebook : le sort du 29 février, la normale utilisée pour l'intensité (médiane ou seuil), et le nombre minimal de jours pour parler de vague.

Partie 2 : prédiction jusqu'en 2100 (maximum, minimum et CO2 de chaque année)

1. Tracer et commenter le maximum annuel de 1940 à 2025.
2. Calculer sa corrélation avec le CO2, puis tester des transformations pour l'augmenter (logarithme, moyenne glissante).
3. Prédire le maximum annuel jusqu'en 2100 sous les 3 scénarios, de façon probabiliste, et décrire la méthode en maths. **C'est le modèle de la compétition.**
4. Donner la distribution du maximum en 2100 et la **probabilité de dépasser 40 °C**. La question peut vouloir dire « pendant l'année 2100 » ou « au moins une fois d'ici 2100 » : on donne les deux.
5. Refaire l'étude pour le minimum annuel.

Le prof note quatre choses : un code concis, des résultats avec leurs unités (°C, ppm), la méthode décrite en maths (LaTeX dans le notebook), et une discussion qui a un sens physique.

Le calendrier

Jusqu'au 23 octobre	Chacun cherche son modèle et lance le benchmark quand il veut.
Vendredi 23 octobre	On compare les scores. Le meilleur modèle est retenu.
Du 23 au 30 octobre	On écrit le notebook ensemble, avec le modèle gagnant.
Vendredi 30 octobre	Dépôt du notebook sur Moodle.